

ESS 배터리 이상 징후 탐지를 위한 시간-주파수 기반 이상 탐지 기법

이연서¹, 김민수², 김파란하늘¹, 현장훈^{1†}

¹ 국립한밭대학교 ² 충남대학교

e-mail : jhhyeon@hanbat.ac.kr

A Time-Frequency Domain CNN for detecting anomalies in ESS batteries

Yeonseo Lee¹, Minsu Kim², Paranhaneul Kim¹ and Janghun Hyeon^{1†}

¹ Hanbat National University ² Chungnam National University

Abstract

Energy storage system (ESS) battery fires have the potential to affect surrounding battery devices, so they must be predicted in advance. To address this issue, this paper proposes a convolutional neural network-based anomaly detection utilizing spectrogram representation of battery data and Short-Time Fourier transform. The proposed method detects temporal-frequency patterns that show the direction of fire. Experimental results demonstrate that this algorithm achieves a test accuracy of 83.3%, confirming its potential to predict ESS battery fires.

I. 서론

최근 전기차 화재 등 리튬이온배터리로 인한 화재가 증가하고 있다. 리튬이온배터리 화재는 리튬이온배터리의 열폭주 현상으로 인해 발생하며, 열폭주 현상은 인접한 배터리로 전파될 가능성이 높다. 따라서 리튬이온배터리의 화재를 예방하기 위해서는 발생할 화재

를 사전에 예측하는 것이 중요하다.

리튬이온배터리는 ESS에서 가장 널리 사용되는 배터리로, 적은 공간에 많은 양의 배터리를 저장하는 ESS의 화재 예측 또한 중요하다.

하지만, 기존 시계열 예측 및 분류에 많이 사용되는 순환신경망(RNN: *Recurrent Neural Network*)은 데이터의 길이가 긴 경우 기울기 소실 또는 기울기 폭주와 같은 문제가 발생하며, 계산적인 이유로 학습과 병렬화가 어렵다는 문제점이 존재한다.[1]

본 논문은 기울기 소실 등의 문제점을 해결하기 위해 단시간 푸리에변환(STFT: *Short-Time Fourier Transform*)과 스펙트로그램(Spectrogram)을 사용한 입력 데이터로 합성곱 신경망(CNN: *Convolutional Neural Network*)을 수행하는 이상 탐지 알고리즘을 제안한다.

II. 본론

2.1 전체 알고리즘 개요

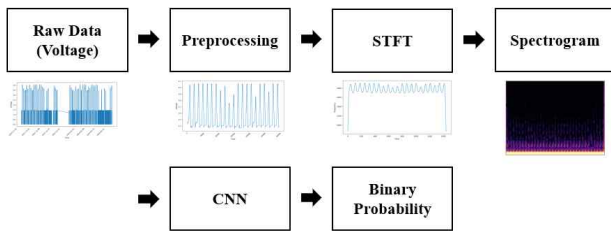


그림 1. 전체 알고리즘 개요

본 논문에서 제안한 이상 탐지 알고리즘의 개요는 그림 1과 같다.

ESS 배터리 전압 값으로 구성되어 있는 다차원 배열을 전처리해 STFT를 수행한다. STFT를 수행한 데이터는 1차원 배열의 형태로 Spectrogram으로 이미지화 하기 위해 1차원 배열의 데이터를 데시벨 단위로 변환한다.

2.2 단시간 푸리에 변환(STFT)

푸리에 변환은 시간 영역에 있는 데이터를 주파수 영역으로 변환하여 신호의 주파수 성분 및 강도를 파악한다.

센서 데이터들은 시간에 따라 통계적 특성이 변하는 비정상 데이터로 구성된다. 비정상 데이터의 경우에는 주파수 성분이 전 주파수 대역에 나타나게 되어, 푸리에 변환을 이용한 시간에 따른 신호 해석이 어렵다.[2] 이를 해결하기 위해 STFT를 사용한다.

2.3 Spectrogram

x축은 시간, y축은 주파수, z축은 그래프의 색으로 나타내며 주파수의 강도를 나타낸다. 소리나 파동을 시각화할 때 사용하는 방법이다.

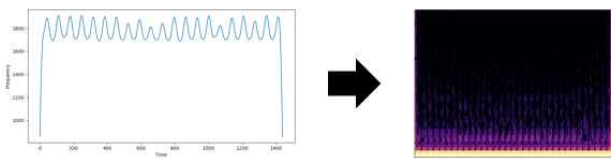


그림 2. 시계열 데이터 및 Spectrogram

위의 그림 2는 시계열 데이터를 Spectrogram으로 시각화한 결과이다. 검은색에 가까울수록 해당 시간에 존재하는 해당 주파수의 강도가 낮았음을 의미한다.

III. 연구 진행

3.1 데이터셋 구축

화재 데이터와 화재가 나지 않은 데이터(비화재 데이터)로 구분되는 ESS 배터리의 전압이 입력으로 사용된다. 1분 단위로 측정되었으며, 센서값이 제대로 측정되지 않은 경우는 모두 0으로 처리되어있다.

배터리가 방전되도 일정량의 전압이 측정된다. 따라서 방전 시의 전압 값 미만의 값은 결측치로 간주한다. 0으로 대체되거나 결측치로 간주된 값은 NaN으로 할당해, 이 값들을 선형 보간하였다. 시작 값이나 끝 값이 NaN일 경우 가장 가까운 측정값을 복사해 채웠다.

3.2 데이터 변환

3.1에서 전처리한 데이터들은 각 rack, module, cell별로 나누어져 배열로 저장되어있다. 각 cell별로 나누어진 값들로 스펙트로그램을 생성하게되면 유사한 스펙트로그램이 다량 생성되어 과적합이 일어날 가능성이 존재한다. 따라서, 같은 rack, module에 있는 모든 cell들을 병합하여 스펙트로그램을 생성한다.

이때, STFT는 1차원 배열에서만 수행 가능하기 때문에 현재 입력으로 들어온 다차원 배열을 1차원으로 평탄화한다.

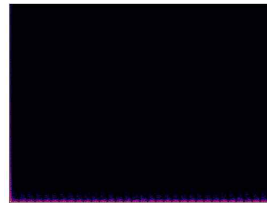


그림 3-1. 전처리만 진행한 스펙트로그램

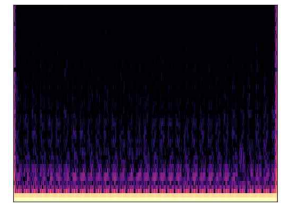


그림 3-2. 특정 주파수 삭제한 스펙트로그램

전처리만 진행한 시계열 데이터는 방전 값 이하의 값은 존재하지 않는다. 따라서 이 데이터로 생성한 spectrogram은 그림 3-1과 같이 유의미한 데이터의 폭이 좁다. 대부분의 주파수 범위에서는 주파수의 강도가 0에 가까워 시각적으로 특징을 파악하기 어렵다.

시각적 특징을 갖지 못한 주파수 범위를 삭제하고 그림 3-2와 같이 CNN의 입력 데이터를 구성한다.

3.3 CNN

Layer	Input Size	Kernel	Output Size
Convolution 1	400 x 300	40 x 30	361 x 271
Pooling 1	361 x 271	3 x 3 (Max)	120 x 90
Convolution 2	120 x 90	12 x 9	105 x 79
Pooling 2	105 x 79	3 x 3 (Max)	35 x 26
Convolution 3	35 x 26	4 x 3	32 x 24
Pooling 3	32 x 24	3 x 3 (Max)	10 x 8
Flatten	10 x 8	-	5120
Dense	5120	-	64
Dropout (0.4)	64	-	64
Dense (Sigmoid)	64	-	1

그림 4. CNN 구조

그림 4는 연구에 사용된 CNN의 구조로, 입력은 스펙트로그램 이미지이다. 4개의 컨볼루션 레이어와 풀

링 레이어를 거친다. 각 4개의 레이어가 끝나면 1차원으로 평탄화를 진행하고 Dense 2개를 통과한다. 한 개의 Dense를 통과한 후에는 과적합 방지를 위해 40% dropout을 실행한다. 마지막으로 Sigmoid 함수로 이진 분류한다.

3.4 결과

제안한 알고리즘은 Accuracy, Precision, Recall로 평가를 진행하며, 화재 데이터를 얼마나 잘 분류하였는가를 판단하는 Recall의 값은 연구의 목적을 얼마나 달성하였는가를 판단하는 핵심 지표가 된다.

학습 데이터는 화재 ESS 배터리 3개, 비화재 ESS 배터리 4개로 구성되어있다.

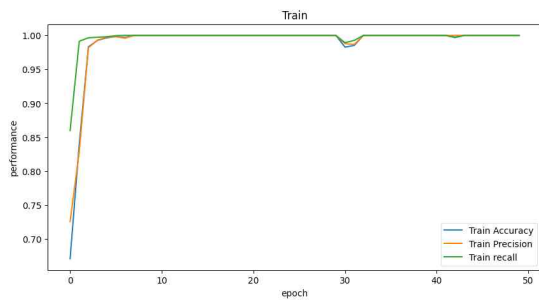


그림 5. epoch에 따른 Train 성능 그래프

그림 5와 같이 학습 데이터의 정확도가 점점 증가하는 추세를 보인다. 최종적인 Train 데이터의 Recall은 1.0으로 Train 데이터에 대해서 모든 화재 데이터를 분류해냈음이 보여진다.

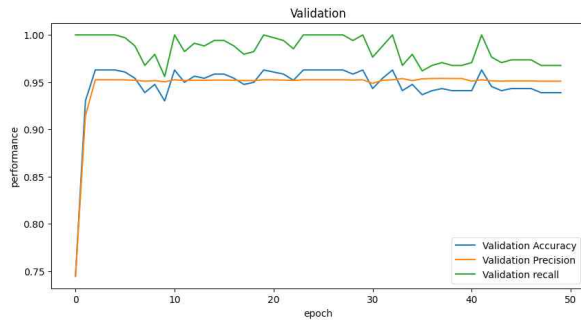


그림 6. epoch에 따른 Validation 성능 그래프

Validation 데이터에 대해서도 accuracy가 증가하는 추세를 보인다.

Precision	Recall	Accuracy
0.75	1.0	0.833

테스트 데이터는 화재 데이터와 비화재 데이터 각각 3개씩 존재한다. 테스트 결과 Precision 0.75, Accuracy 0.833의 수치를 가진다.

본 연구 목적을 평가하기 위한 핵심 지표인 Recall은 1.0으로 모든 화재를 예측하는 데 성공하였다고 판

단할 수 있다.

IV. 결론 및 향후 연구 방향

ESS 배터리의 시계열 데이터를 이용해 화재를 예측하는 여러 연구가 있다. 본 연구는 시계열 데이터를 시각화해 이미지로서 처리하는 알고리즘을 제안함으로써, 효과적으로 학습시킬 수 있는 또 하나의 방법을 제시한다.

ESS 배터리의 전압을 시각화해 학습시킴으로써 화재/비화재 분류에 0.833의 높은 정확도를 가지는 모델을 제작했다.

향후, 보간법을 강화하고 과하게 넓은 커널을 최적화할 방법을 찾아 더 높은 정확도의 모델이 구현되기를 기대한다.

Acknowledgement

본 연구는 2025년 과학기술정보통신부 및 정보통신기획평가원의 SW중심대학사업의 연구결과로 수행되었음”(2022-0-01068)

본 연구는 2025년도 산업통상자원부 및 한국산업기술기획평가원(KEIT) 연구비 지원에 의한 연구임(과제번호: RS-2024-00432506, RS-2024-0042780)

참고문헌

- [1] 심준현 and 김철진. (2023). 시계열 이미지 데이터 기반 상품추천을 위한 CNN 모델 성능 비교 연구. 한국지식정보기술학회 논문지, 18(5), 1253-1264.
- [2] 강민규, 이현소, 황성호, 김경석. Short Time Fourier Transform 알고리즘을 적용한 효율적인 스펙트럼 센싱 기법. 한국방송미디어공학회 학술발표대회 논문집,